ESTUDO DE CASO: LOJA DE QUADRINHOS HQMANIA

A loja de quadrinhos HQMania deseja utilizar Inteligência Artificial para analisar automaticamente as avaliações deixadas por seus clientes. Atualmente, as avaliações são analisadas manualmente, o que demanda tempo. A empresa deseja desenvolver um modelo de Processamento de Linguagem Natural (PLN) capaz de identificar se uma avaliação é positiva ou negativa. Por exemplo: "O quadrinho possui uma história incrível e os desenhos são excelentes." Essa avaliação deve ser classificada como: 1 (Positiva). Enquanto: "A história é muito fraca e a qualidade do quadrinho deixou a desejar." Deve ser classificada como: 0 (Negativa). Para realizar essa tarefa, você deverá implementar uma Rede Neural Perceptron de uma única camada. Desenvolva, em Python, um modelo de Perceptron capaz de classificar avaliações de clientes da HQMania como positivas ou negativas, utilizando características extraídas dos textos. O projeto deverá seguir as seguintes etapas: Avaliações → Pré-processamento → Vetorização → Perceptron → Classificação.

1. CRIAÇÃO DA BASE DE DADOS

Crie uma base de dados fictícia contendo pelo menos 20 avaliações de clientes sobre quadrinhos. Cada avaliação deverá possuir:

- id: código de identificação da avaliação
- texto da avaliação
- classe: 1 (avaliação positiva) e 0 (avaliação negativa)

Procure criar avaliações variadas, evitando utilizar exatamente as mesmas palavras em todos os exemplos.

2. PRÉ-PROCESSAMENTO DOS TEXTOS

Antes de utilizar os textos na rede neural, realize um processo simples de pré-processamento de PLN. Para cada avaliação:

1. Converter o texto para letras minúsculas;

2. Remover pontuação;
3. Separar o texto em palavras;
4. Remover palavras muito comuns (stopwords).

3. TRANSFORMAÇÃO DOS TEXTOS EM NÚMEROS

Uma rede Perceptron não consegue trabalhar diretamente com textos. Portanto, transforme as avaliações em uma representação numérica utilizando o modelo Bag of Words (BoW). Crie um vocabulário contendo as principais palavras.
Por exemplo:
["história", "incrível", "personagens", "excelentes",
"fraca", "cansativa", "divertido", "fantástica"]

Cada avaliação deverá ser representada por um vetor.
Por exemplo, considerando o vocabulário:
["história", "incrível", "excelente", "fraca"]

A frase:
"A história é incrível"

poderia ser representada por:
[1, 1, 0, 0]

Enquanto:
"A história é fraca"

seria:
[1, 0, 0, 1]

Utilize 0 quando a palavra não aparece e 1 quando a palavra aparece. Importante: implemente a transformação Bag of Words manualmente, utilizando apenas Python. Não utilize CountVectorizer ou outras ferramentas prontas do scikit-learn.

4. IMPLEMENTAÇÃO DO PERCEPTRON

Implemente, em Python, uma rede Perceptron de uma única camada. Não utilize bibliotecas de Machine Learning, como: TensorFlow, Keras, Scikit-learn, PyTorch, etc). Podem ser utilizadas bibliotecas básicas do Python, como: randomimport, numpy, pandas, etc.

A rede deverá possuir:
- um peso para cada característica do vetor;
- um bias;
- pesos iniciais aleatórios;
- taxa de aprendizagem;
- função de ativação.

Função de ativação
Utilize a seguinte função:
f(soma) = 1, se soma > 0.5
0, caso contrário

5. TREINAMENTO

Treine o Perceptron utilizando os exemplos da base. Lembre-se que para cada avaliação, você deverá:

1. Calcule a soma ponderada: $\text{Soma} = (x_1 * w_1) + (x_2 * w_2) + \cdots + (x_n * w_n)$
2. Aplique a função de ativação;
3. Compare a saída obtida com a classe correta;
4. Calcule o erro: $erro = classe_{real} - classe_prevista$
5. Atualize os pesos: $\text{peso} = \text{peso} + \text{taxa_aprendizagem} * \text{erro} * \text{entrada}$

Utilize, por exemplo: taxa_aprendizagem = 0.1 e no máximo: 100 épocas. O treinamento poderá ser interrompido antecipadamente caso não ocorram erros em uma determinada época.

6. TESTE DO MODELO

Após o treinamento, utilize as avaliações da base para testar o Perceptron. Para cada avaliação, apresente:

- texto;
- classe real;
- classe prevista;
- resultado.

7. CÁLCULO DA PORCENTAGEM DE ACERTO

Ao final dos testes, calcule a acurácia do modelo. Para isso, utilize:

$$Acurácia = \frac{(número\ de\ classificações\ corretas)}{(número\ total\ de\ avaliações)} * 100$$

Apresente o resultado, por exemplo:

- Total de avaliações: 20
- Classificações corretas: 17
- Classificações incorretas: 3
- Acurácia: 85%

8. TESTE COM NOVAS AVALIAÇÕES

Depois de treinar a rede, crie pelo menos 5 novas avaliações que não façam parte da base de treinamento.

9. ANÁLISE DOS RESULTADOS

Após executar o programa, responda às seguintes questões:
a) A rede aprendeu a classificar as avaliações? Explique sua resposta utilizando a acurácia obtida durante os testes.

b) Quantas avaliações foram classificadas incorretamente? Apresente a quantidade e, se possível, indique quais avaliações foram classificadas incorretamente.

c) Por que ocorreram os erros? Considere fatores como:

- palavras que aparecem tanto em avaliações positivas quanto negativas;
- tamanho reduzido da base;
- limitações do modelo Bag of Words;
- ausência de análise de contexto;
- palavras com significado semelhante;
- ironia ou ambiguidade.